МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ (НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Факультет информационных технологий и прикладной математики Кафедра вычислительной математики и программирования

Отчет по лабораторной работе №2

«Оценка качества поиска»

по курсу

«Информационный поиск»

Группа: 80-106М

Выполнил: Забелин М.К.

Преподаватель: Калинин А.Л.

ЛР2: Оценка качества поиска

Необходимо оценить качество своего поиска и сравнить их с двумя альтернативами (для Википедии можно собственный поиск по Википедии, поиск Google или Яндекса с ограничением по сайту Википедии). Как минимум, нужно измерить Р, DCG, NDCG и ERR уровней @1, @3 и @5, приветствуется использование дополнительных метрик качества. Для оценки качества необходимо придумать 30 запросов, отражающих интересы пользователей или, если есть доступ к настоящим запросам пользователей, то выбрать репрезентативную подборку.

Примеры запросов по тематикам «Техника» и «Информация»:

история AMD USB-накопитель агенство Эврика алгоритм Витерби преимущества метаанализа стандарт Stereo Домашний каталог функция MD5 барабан и жесткий диск электронное удостоверение личности Технологическая школа IBM в России Когда появились карманные часы булевая алгебра измерительные механизмы Калькулятор МК 56 катоды косвенного накала смартфон Palm Treo формат wmv инструмент цистра типографское клише чем наполнен Шарльер вертолет Як влияет ли ЭМИ на людей чем является процесс с независимыми приращениями примеры профессиональных стандартов процесс сквозного шифрования список маломассивных звезд что такое тезурус что символизируют три обезъяны примеры трилогии

С точки зрения сложности интересными являются запросы:

- Домашний каталог (т. к. это редкое словосочетание, а по отдельности слова встречаются часто)
- влияет ли ЭМИ на людей (добавление частицы «ли»)
- Когда появились карманные часы (в документе есть утверждение об этом, но слова там в другом порядке)
- чем является процесс с независимыми приращениями (в оригинале обратный порядок слов без местоимения «что»)

Оценивание производилось следующим образом. Максимальную оценку «5» я ставил, если запрашиваемое словосочетание было найдено в нужном клонтексте (например, слово «барабан» в сочетании со словами «жесткий диск» было употреблено в смысле устройства компьютерной памяти, а не музыкального инструмента). «4» ставилась, если запрос содержал уточнение о запрашиваемом понятии (например, «чем заправляются автобусы?»), но в документе есть просто описано, что из себя это понятие представляет без ответа на уточнение. «3» ставилась, если запрашиваемое слово было в неправильном контексте или содержал не всю часть словосочетания, однако поисковик понял, какая часть словосочетания содержит основную смысловую нагрузку. «2» ставилась, если документ просто содержит какое-то слово из запроса. «1» - если документ вообще не подходит.

Запросы, написанные выше, производились поисковиками Google и Яндекс с ограничением по сайту Википедии.

Оценки, на основании которых считались метрики:

https://github.com/Mikhail-Z/MAI/blob/master/sem10/Informational %20Search/is2/yandex_queries_scores.csv

https://github.com/Mikhail-Z/MAI/blob/master/sem10/Informational %20Search/is2/google queries scores.csv

При поиске в Google проблемы были со следующими запросами:

- 1. Калькулятор МК-56. В результаты попали и другие калькуляторы серии «МК», но была статья про калькуляторы вообще
- 2. Что символизируют три обезъяны. В выдачу попали просто статьи об обезъянах.
- 3. стандарт Stereo. В выдачу хоть и попали статьи, касающиеся звука, но так как Stereo было латиницей написано, то ожидалась статья про Stereo 8.
- 4. вертолет Як в выдачу попала статья про вертолеты в общем.

Однако стоит заметить, что Google очень хорошо звлекает именно объект поиска от уточняющих запрос слов. Например, на запрос «Чем наполнен Шарльер» все статьи содержали ответ на этот вопрос.

Что касается поиска Яндекса, то мне он понравился меньше. Очень часто документы не содержали всех слов словосочетания, что привело к более низким оценкам. Например, по запросу «Истоия AMD» большая часть документов была об AMD, но не содержала историю компании. Либо была не об AMD, а о дочерней компании.

Для оценки качества поиска были выбраны следующие оценки P, Err, Dcg, Ndcg. Их определение можно найти в файле https://github.com/Mikhail-Z/MAI/blob/master/sem10/Informational%20Search/is2/metrics.py:

Результаты метрик P, DCG, NDCG и ERR уровней @1, @3 и @5 можно для поисковиков Яндекс и Google можно увидеть в файлах:

https://github.com/Mikhail-Z/MAI/blob/master/sem10/Informational %20Search/is2/out_yandex_queries_scores.csv

https://github.com/Mikhail-Z/MAI/blob/master/sem10/Informational %20Search/is2/out google queries scores.csv

Средние показатели поисковиков по 30 запросам:

Яндекс:

P@1: 4.9

P@3: 4.444466666666667

P@5: 4.226666666666667

DCG@1: 29.4

DCG@3: 53.67513333333333

DCG@5: 68.22213333333333

NDCG@1: 0.9828

NDCG@3: 0.9457666666666666

NDCG@5: 0.9803

ERR@1: 0.9659

ERR@3: 0.971299999999999

ERR@5: 0.97213333333333333

Google:

P@1: 4.966666666666667

P@3: 4.63336666666666

P@5: 4.4533333333333333

DCG@1: 30.4666666666665

DCG@3: 57.60193333333333

DCG@5: 75.00173333333333

NDCG@1: 0.9828

NDCG@3: 0.9466666666666667

NDCG@5: 0.98493333333333333

ERR@1: 0.967966666666666

ERR@3: 0.974366666666666

ERR@5: 0.974666666666666

По всем метрикам Google чуть лучше Яндекса при поиске по Википедии.

Вывод

Познакомился с различными метриками для оценки релевантности результатов поиска.

Ссылка на Git репозиторий

https://github.com/Mikhail-Z/MAI/tree/master/sem10/Informational%20 Search/is 20 Search/is 20